

PROJECT UPGRADE BRIEF / 决策版

工勘填报 Agent 大厂研究与项目迭代建议

面向互联网大厂面试 · 基于当前项目与官方研究证据

调研截止 2026-10-01。近期维护工具与仍适用的 2024-2025 年论文同时纳入；版本、论文首稿与发布页日期分开记录。

推荐定位

把项目定位为“可核对原文证据的工勘填报 Agent 平台”。保留 Python + Go + Vue + Qdrant，优先补真实模板、索引版本与领域评测，再依据坏例引入结构解析或多模态。

最先做的三件事	为什么值得做
01 新模板字段分析与版本化索引	从历史固定表单走向真实上传；构建失败不破坏已有知识库。
02 人工 gold、盲测与风险-覆盖评测	用可复现结果证明正确写回、拒答与成本，形成面试里的实验依据。
03 调用预算与每轮动作界面	将现有受约束动作扩展为可观察、可停止、可解释的长任务。

当前已有增量：上传来源进入真实检索；动作过滤实际执行；Python/Go/Vue 原文定位与字段证据工作台。完整框架迁移不作为第一优先级。

阅读导航：02 项目诊断 / 03 Google / 04 阿里与解析候选 / 05 建议清单 / 06 技术规格 / 07 评测 / 08 界面 / 09 面试与实施 / 10 官方来源。

本报告列的是建议与已验证工程事实。尚无真实模型业务准确率、成本下降或跨机房泛化成绩。

架构稳定，补齐业务闭环



Qdrant 分层知识检索 / 外部模型服务 / Excel audit / manifest 稳定契约

三类结果分别可见：原始回答、写回决策、引用定位。保留权限与 checkpoint 续跑。

能力	当前状态	下一步缺口
上传与召回	已补四类 uploaded_* 独立检索层；原文与向量输入分离。	完整结构解析、递归 OLE 仍需按坏例深化。
Agent 动作	已执行来源/层级/namespace 限制；非法动作空结果并记录原因。	真实 token/call/time 预算和停止收益观测。
引用与界面	逐字定位、SHA256、Unicode 区间，Go 校验与 Vue 高亮已落地。	专门的逐轮动作视图与索引新鲜度证明。
模板与索引	已有离线分析、DB 版本/current 与 ready 切换；填表仍读历史 Step12，入库覆盖同 namespace。	上传模板字段穿透；任务固定物理快照；原子发布与真实回滚。
评测与部署	工程契约与匿名合成页面验收已有；现成部署包为旧 ARM64 构建。	人工领域 gold、真实模型对比；最新镜像重建和部署验收。

已验证范围

实施记录：Python 250 项测试通过，Go 全量测试通过，Web 23 项测试、类型检查与生产构建通过。浏览器验收覆盖字段筛选、emoji 高亮、键盘操作及 768/390/320 像素布局。

这些检查证明工程契约与界面行为；合成 fixture 使用确定性模型替身，不能证明真实业务准确率或成本改善。AgentScope 当前是受控 callback 角色编排，不能描述为原生多模型自主协商。

优先借鉴证据与评测方法

官方研究 / 仓库	项目中的用法	接入决定
LangExtract [1] v1.7.0 · 2026-09-13 Apache-2.0	让模型提供候选 quote，再由代码核对原文、哈希和区间。当前旁路已借鉴这一思想。	高优先级方法借鉴；不新增框架。默认 fuzzy alignment 不宜直接作为安全写回依据。
Sufficient Context [2] 首稿 2024-11-09 v3 2025-04-23	把“上下文不充分”与“上下文充分但答错”分开统计；评估可回答性与选择性拒答。	高优先级评测方法；在工勘领域重新标注充分性，不照搬论文成绩。
FACTS Suite [3] 官方发布 2025-12-09 Grounding 基础 [16]	借鉴基础 Grounding 的两阶段评价：任务完成与事实支撑；参考 Suite 的公开/私有盲测。	高优先级方法借鉴；通用 benchmark 分数不代表本项目效果。
ADK [4] v2.10.0 · 2026-09-25 Apache-2.0	参考轨迹评测、模型/工具调用数、token 和耗时观测，映射到现有 manifest/trace。	中优先级参考；现有 AgentScope/Worker 已承担运行时，不立即迁移。

关键技术边界

原文定位只证明这段字存在，不证明它支持答案。机房范围、现状/规划、单台/总量、单位与必需槽仍需原有门控和领域评测。当前定位旁路不改变写回策略。

建议实验：同一份冻结知识快照，对上下文充分/不充分分别报告答对、答错、拒答；在 validation 校准阈值，在 test 绘制错误写回风险与覆盖率曲线。

A2A 只有在 OCR/检索真正拆成独立 Agent 服务、需要跨服务任务与产物互操作时再评估；同进程角色不需要额外协议。

日期口径：LangExtract、ADK 为官方 release feed 的 updated 日期，不等同于精确首次发布日期；ADK release notes 内标 09-24，feed 为 09-25。

深化已有依赖，隔离可选实验

候选与最新证据	建议	当前边界
AgentScope [5] v2.0.9 · PyPI 上传 2026-09-28 · Apache-2.0	用事件/middleware 和 pipeline 深化动作日志、预算与状态路由。	已有 $\geq 2, < 3$ 依赖；SOP 为实验性功能。Runtime 能力已合入 2.0，不另建控制平面 [6]。
Qwen3 文本模型 [7] 首稿 2025-06-05 v3 2025-06-11	当前已用 Qwen3-Embedding-8B；做领域 instruction 和 rerank 候选预算消融。	不是新引入 embedding；模型卡许可与代码/数据许可分别确认。
EvalScope [8] PyPI 1.12.0 2026-09-16 · Apache-2.0	在独立离线环境接自定义字段任务、检索指标、Agent trace 与压测。	先完成领域 gold；LLM judge 需人工校准，不能代替坐标、权限和状态校验。
Qwen3-VL [9] 首稿 2026-01-08 v2 2026-01-19	图片/截图子集做独立 collection、adapter 与成本对比。	当前客户端只接受字符串；改模型名不等于支持图片。不同向量空间需重建索引。
DeepResearch [10] 模型 2025-09-17 报告 v3 2026-05-18	参考证据驱动补检索和停止策略，受控旁路测试 replanner。	报告首稿 2025-10-28；网页研究整套流程不直接适配私有工勘字段，不作整体迁移。

解析候选：按真实坏例接入

Docling v2.131.0 (2026-09-29 , MIT) [11] 用于 Office/PDF 结构、表格与父子关系；PaddleOCR v3.7.0 (2026-06-11 , Apache-2.0) [12] 仅为扫描件/图片提供 fallback。原生 Office 优先读结构；递归 OLE 仍需自有适配器。

八项增量，按验收收益排序

优先级 / 状态	修改建议	验收依据 / 面试价值
P0 · 待接入	新模板字段链路 上传→分析→form_items→Worker；绑定自身 sheet/cell 与合并范围。	移动行列、重排 sheet 的新模板仍写入正确位置；体现跨模块业务契约。
P0 · 待完善	不可变快照与原子发布/回滚 build → validate → activate；旧版延后清理。	批量 upsert 中断仍可查询旧版；体现长任务状态、幂等与故障隔离。
P0 · 待实施	领域 gold 与冻结盲测 按机房/文档分组，覆盖拒答、单位、状态与位置。	输出字段/证据/写回指标及配对差异；证明收益与局限。
P1 · 部分已有	预算与停止策略 补 calls、tokens、wall time 与重复证据停止。	预算耗尽明确进入复核；缺 usage 保持 unknown；体现成本治理。
P1 · 工作台已有	逐轮动作视图 展示动作约束、新增证据、停止原因、耗时。	与真实 trace/manifest 一致；支持失败、恢复、旧任务；体现可解释产品设计。
P1 · 门控已有	充分性与写回阈值校准 用领域坏例验证补检索、拒答和复核策略。	阈值只在 validation 选择；错误风险与覆盖同报；体现业务边界判断。
P2 · 待实验	结构解析/OCR adapter 统一 source_anchor、raw_source_text、父子关系。	合并表格、宽表、扫描数字坏例分组改善；体现从问题选技术。
P2 · 待实验	图片证据检索 Qwen3-VL 独立图像子集与索引。	文本 baseline 保留，比较图片问题收益；视觉命中仍不直接放行数值。

建议先完成前三项，再按失败样本决定解析和多模态；型号/单位检索若是短板，可另做 instruction、sparse/RRF 受控对照 [15]。GraphRAG 与 AutoGen README 已标 maintenance mode [13][14]，不优先迁移；RL/GPU 栈待可信 gold、reward 与资源具备后再研究。

模板、索引、测试集各有完成条件

A. 上传模板成为字段位置的唯一来源

入口：src/nested_doc_rag/form/analyze.py、cli.py 与 Go command_builder.go。已有离线分析、CLI --form-items 覆盖参数和模板物化，但 Go 未透传 form_items 或触发分析；应接通上传→分析→字段→Worker，记录模板哈希，未知布局提供确认。

验收：同一问题移动到新列、新 sheet 后位置正确；空标题、重复字段、合并单元格进入可解释复核；公式与非空单元格保护保留；checkpoint 使用稳定字段身份。

B. 构建新索引，不先破坏旧知识

入口：ingestion.py、qdrant_retriever.py、Go knowledge/service.go 与 form/payload.go。已有 DB 版本 /current 指针，但默认复用物理 namespace，Worker 未穿透版本 ID；旧版 archived 与 ready 限制妨碍常规回滚。构建验证后再发布，保留不可变旧快照，并原子协调状态/current 更新。

验收：V2 构建或发布任一步失败，V1 仍可查询且不误发 ready；V1 任务的 target/global 都冻结旧版，跨切换不混入 V2；回滚实际恢复 V1；模型向量空间不混用。

C. 领域 gold 与最小坏例集

入口：evaluation/field_metrics.py、gold_fields.jsonl 与独立实验配置。建议起步人工标注 100-150 个字段、20-30 份代表性资料；这是建议规模，不是现有数据量。gold 包含答案、目标 cell、来源 anchor、机房/粒度/时间、单位、必需槽、可回答性与上下文充分性。

验收：机房/文档分组划分 train、validation、test；gold 和已填写答案不进入检索或生成 prompt；test 冻结后再运行。无法留出完整机房时明确报告评测局限。

共同不变量

保留 raw prediction 与 Overlay 分离、owner-only 下载、manifest 校验、公式/重复目标保护、任务取消、checkpoint 续跑与中断状态恢复。新增解析或检索路径必须遵守原有机房范围和来源约束。

先定义指标，再写简历数字

指标	定义与证据	必须同时报告
字段与状态正确率	实际答案/status 对人工 gold，单位与别名规范透明。	全字段分母；可回答/不可回答分别统计。
检索 Recall@k	候选集对 gold 文档/anchor，而非只对最终引用 ID。	错机房、型号、数字、结构类别分项。
定位与语义支撑	分别核对 hash/quote/区间，以及主张是否受正确范围证据支持。	exact 不是语义正确；source ID 非空不是 grounding。
写回 precision	答案、目标位置与证据均正确的实际写入 / 全部实际写入。	覆盖率、错误类别、置信区间；零写入时未定义。
拒答与风险-覆盖	不可回答 gold 对拒答；阈值变化时错误风险与覆盖同报。	validation 校准、test 冻结；partial 不全算正确拒答。
效率与成本	p50/p95、真实 calls/tokens、单字段与新增正确字段成本。	缺 usage 为 unknown；价格/模型/日期版本化。

四组先行消融

① 修复上传契约后的单轮分层 RAG；② 加真实动作约束；③ 加动作预算/停止；④ 按坏例只加一种解析或检索方案。固定数据快照、模型、prompt 与配置；研究某因素时仅改该因素。概率模型建议重复 3 次并报告配对差异。

当前 provenance 不影响门控，单独报告定位质量与审计收益。若未来将定位用于拒写，需另设 gate 实验，比较 precision 与 coverage，不能归因给当前旁路。

必测坏例：正确值但错机房、规划容量当现网、总量填单台、必需槽缺失、重复引用、OCR 8/3、冲突来源、公式/合并/重复目标、新模板移列、checkpoint 中断恢复。

让复核者看清答案、写回与原文

正式 Vue 详情页截图 · 匿名合成契约资料 · 非线上业务效果



已经落地	建议继续补充
全字段列表、搜索与状态筛选；原始答案、实际写回和门控理由分别展示。	逐轮动作面板：动作来源限制、返回/新增 chunk 数、停止原因与耗时。
代码校验逐字原文高亮；重复/失配引用不强行高亮；来源逐条可核对。	来源版本与新鲜度：只有版本化索引完成后再展示可信版本状态。
四项主指标、未知进度不虚构；中文原因、旧任务与空/失败状态兼容。	真实数据驱动的风险-覆盖与成本图；在领域评测完成后展示实验结果。

视觉原则：统一字号/间距/状态色，保持左侧选字段、右侧看证据的固定关系；移动端堆叠，提供键盘焦点；长原文安全转义。320/390/768 像素无水平溢出已验收。合成演示应持续标注，不混入真实运行指标。

用工程事实和实验边界讲项目

阶段	可审查交付	完成判据
下一轮 P0	新模板分析、版本化索引、领域 gold；最小真实端到端样例。	模板变化正确；索引故障可回滚；冻结集无事实泄漏。
随后 P1	调用预算/停止、每轮动作 UI；坏例需要的解析 adapter。	动作实际执行；预算耗尽可解释；新路径对 baseline 有证据收益。
实验 P2	EvalScope 离线 adapter、instruction/hybrid/图片子集实验。	固定变量、配对对比、人工抽检，报质量与成本。
发布准备	重建对应架构镜像、配置校验、部署与业务验收。	上线前后产物可追溯；新版本实际服务验收。

推荐五分钟演示

展示一个可定位引用 → 重复引用待消歧 → 引用失配与实际写回分开 → 未找到/错机房复核 → 一次补检索动作 → checkpoint 续跑与真实 Excel audit。当前使用匿名合成案例；后续换成授权脱敏业务样例。

可以写进面试材料的当前事实

发现并修复上传来源与生产过滤的契约错误；将动作约束落实到真实查询；设计不侵入预测的引用定位旁路；跨 Python/Go/Vue 统一 Unicode 与哈希；通过归档归属和路径校验保护证据读取。

暂不能写：业务准确率提升、成本下降百分比、跨机房泛化、原生多 Agent 自主协商或完整论文复现。待真实盲测后再写 N、precision、coverage、P95 与成本；不要使用未经测量的简历数字。

部署现状

已存在约 3.20 GiB 的 2026-07-06 Linux ARM64 完整部署包；不含本轮迭代。7 月 10 日修复版完整压缩包与应用镜像归档缺失，现存配置/依赖镜像及 API 补丁不能替代完整包。部署最新代码需重建镜像与压缩包，并匹配目标架构。

09 / 官方来源与复核入口

版本和事实都可回到证据

- [1] Google LangExtract v1.7.0 · release feed 2026-09-13 · Apache-2.0
<https://github.com/google/langextract/releases/tag/v1.7.0>
- [2] Sufficient Context: A New Lens on RAG Systems · arXiv:2411.06037
<https://arxiv.org/abs/2411.06037>
- [3] Google DeepMind FACTS Benchmark Suite · 2025-12-09
<https://deepmind.google/blog/facts-benchmark-suite-systematically-evaluating-the-factuality-of-large-language-models/>
- [4] Google ADK v2.10.0 · release feed 2026-09-25 · Apache-2.0
<https://github.com/google/adk-python/releases/tag/v2.10.0>
- [5] AgentScope v2.0.9 · PyPI 上传 2026-09-28 · Apache-2.0
<https://github.com/agentscope-ai/agentscope/releases/tag/v2.0.9>
- [6] AgentScope Runtime · README 说明合入 2.0 的迁移状态
<https://github.com/agentscope-ai/agentscope-runtime>
- [7] Qwen3 Embedding / Reranker · 首稿 2025-06-05 / v3 2025-06-11
<https://github.com/QwenLM/Qwen3-Embedding>
- [8] EvalScope PyPI 1.12.0 · 2026-09-16 · Apache-2.0
<https://pypi.org/project/evalscope/1.12.0/>
- [9] Qwen3-VL Embedding / Reranker · 首稿 2026-01-08 / v2 2026-01-19
<https://github.com/QwenLM/Qwen3-VL-Embedding>
- [10] Tongyi DeepResearch · arXiv:2510.24701 · v3 2026-05-18
<https://github.com/Alibaba-NLP/DeepResearch>
- [11] Docling v2.131.0 · 2026-09-29 · MIT
<https://github.com/docling-project/docling/releases/tag/v2.131.0>
- [12] PaddleOCR v3.7.0 · 2026-06-11 · Apache-2.0
<https://github.com/PaddlePaddle/PaddleOCR/releases/tag/v3.7.0>
- [13] Microsoft GraphRAG · README maintenance mode · MIT
<https://github.com/microsoft/graphrag>
- [14] Microsoft AutoGen · README maintenance mode · 代码 MIT
<https://github.com/microsoft/autogen>
- [15] Qdrant Hybrid Queries · 作为后续 sparse/RRF 实验参考
<https://qdrant.tech/documentation/concepts/hybrid-queries/>
- [16] FACTS Grounding · 基础论文 arXiv:2501.03200 · 首稿 2025-01-06
<https://arxiv.org/abs/2501.03200>

项目内审计入口

docs/research/2026-10-01-interview-upgrade.md : 完整筛选与规格。
docs/research/2026-10-01-implementation.md : 实现、验证命令与限制。
docs/research/2026-10-01-sources.json : 121 份官方证据的 URL、获取时间、大小、SHA256 ; 快照已重新校验。

许可说明 : 代码、权重和数据许可分别确认。Qwen 文本模型卡已确认 Apache-2.0 , 不能据此推断整仓所有资产 ; 论文、FACTS 数据与作者仓库不作为业务 SDK 复制。工具版本是调研截止日可核实状态 , 不代表未来仍为最新。